

MLOps Biomasse-Vorhersage-Pipeline

Dieses Repository enthält eine automatisierte Machine-Learning-Pipeline zur Vorhersage von Pflanzenbiomasse.

Die Pipeline nutzt **Dagster** für die Orchestrierung und **MLflow** für das Experiment-Tracking.

Sie transformiert Rohbilder und Metadaten in ein trainiertes ResNet-Regressionsmodell.

1. Pipeline-Architektur

Die Pipeline besteht aus den folgenden Dagster-Assets:

- **raw_dataset**

Lädt die Metadaten (Excel) und validiert, ob die Bildpfade auf der Festplatte existieren.

- **eda_plots** (optional)

Erstellt Plots zur explorativen Datenanalyse (z. B. Verteilung der Zielvariable) und speichert diese unter **figures/**.

- **preprocessed_data**

Passt die Bildgröße an, normalisiert die Bilder, führt einen Train/Validation-Split durch und erstellt PyTorch DataLoaders.

- **trained_model**

Trainiert ein ResNet-Modell (ResNet18 oder ResNet50).

Integration: Nutzt MLflow, um Hyperparameter zu tracken, Trainingsmetriken (Loss, R²) pro Epoche zu loggen und das beste Modell als Artefakt zu speichern.

- **model_evaluation**

Lädt das beste Modell, führt Inferenz auf dem Validierungsdatensatz durch, berechnet den MSE (Mean Squared Error) und erstellt einen „Prediction vs. Actual“-Scatter-Plot.

2. Installationsanleitung

Voraussetzungen

- Python 3.8 oder höher
- Virtuelle Umgebung (empfohlen)

Installation

Installieren Sie die benötigten Abhängigkeiten:

```
pip install dagster dagster-webserver dagster-mlflow mlflow pandas torch
torchvision matplotlib openpyxl numpy
```

oder

```
pip install -r requirements.txt
```

Stellen Sie sicher, dass der Datensatz im Hauptverzeichnis (Root) mit der folgenden Struktur vorhanden ist:

MLOps_P2_17/2025_10_13_mllops_biomass_data/mllops_biomass_data/digital_biomass_labels.xlsx

MLOps_P2_17/2025_10_13_mllops_biomass_data/mllops_biomass_data/images_med_res/

3. Ausführen der Pipeline

Um die Pipeline korrekt auszuführen, müssen zwei Dienste in separaten Terminal-Fenstern gestartet werden.

Schritt 1: MLflow Tracking Server starten

Dieser Server übernimmt das Logging der Experimente.

```
mlflow server --port 5001
```

Zugriff auf die UI: <http://localhost:5001>

Schritt 2: Dagster Dev Server starten

Dieser Befehl startet den Dagster Daemon und die Weboberfläche.

```
dagster dev -f dagster_pipeline.py
```

Zugriff auf die UI: <http://localhost:3000>

3. Ausführung

1. Öffnen Sie die Dagster UI unter <http://localhost:3000>.
2. Navigieren Sie zum Tab Assets (oder Lineage).
3. Klicken Sie oben rechts auf "Materialize all", um die gesamte Pipeline auszuführen.

4. Ergebnisse

Getrackte Parameter & Metriken

Das Asset `trained_model` loggt Folgendes in MLflow:

1. **Parameter:** `epochs`, `batch_size`, `learning_rate`, `model` (z. B. `resnet18`), `optimizer`.
2. **Metriken:** `train_loss`, `val_loss`, `val_r2`.
3. **Artefakte:** Die Gewichte des besten Modells (`best_model_mlflow.pth`).

5. Evaluierung


Nach einem erfolgreichen Durchlauf werden die Ergebnisse **lokal** gespeichert:

Metriken: results/metrics.txt (enthält den Validierungs-MSE).

Plots: results/pred_vs_actual.png und figures/target_distribution.png.

Screenshots

Dagster Lineage (Erfolgreicher Durchlauf):



MLflow Experiment Tracking:

The screenshot shows the MLflow interface on a Mac OS X system. The title bar indicates it's running on 127.0.0.1 at 11:10 AM on Monday, December 8, 2025. The main content area displays a run named 'dagster_resnet_training' under the experiment 'plant_biomass_pipeline'. The left sidebar has tabs for Overview, Model metrics, System metrics, Traces, and Artifacts. The Overview tab is selected. The right sidebar contains sections for About this run, Datasets, Tags, and Registered models, all of which show 'None'.

Metrics (3)

Metric	Value
val_r2	0.8115066898928402
val_loss	0.014697787270921728
train_loss	0.03559899121381373

Parameters (5)

Parameter	Value
optimizer	Adam
learning_rate	0.001
epochs	3
model	resnet18
batch_size	32

Dagster Config:

The screenshot shows the Dagster interface on a Mac OS X system. The title bar indicates it's running on 127.0.0.1 at 10:56 AM on Tuesday, December 11, 2025. The main content area shows the configuration for the 'model_evaluation' asset under the 'Launchpad' section. The configuration code is as follows:

```

1 ops:
2   trained_model:
3     config:
4       batch_size: 32
5       epochs: 3
6       learning_rate: 0.001
7       model_name: resnet18
8

```

The interface includes a code editor with syntax highlighting for YAML, a preview pane showing the configuration structure, and a sidebar with navigation links like Overview, Runs, Catalog, Automation, Lineage, Deployment, and Settings.

Dagster Markdown Plot: Zum einsehen des Plots muss man auf das asset `model_evaluation` klicken und unter `evaluation_plot` auf "Show Markdown"

